



MVP - Engenharia de Dados

Produtividade de equipes na indústria de confecção

Izis Dornelas de Paula

Email: izisdornelas@gmail.com

GitHub: <https://github.com/izisdornelas>

Discord: izisdornelas

Sprint: Engenharia de Dados (40530010057_20260_01)

Repositório: <https://github.com/izisdornelas/mvp-engenharia-dados-produtividade>

Este projeto reúne dados de produtividade de equipes, preserva a fonte original, aplica regras de padronização e disponibiliza tabelas para responder a perguntas de gestão. O pipeline foi executado no Databricks Free Edition sobre 1.197 registros de uma base pública da UCI Machine Learning Repository.

Sumário

1 Contexto de Negócios e Perguntas	2
Fonte dos dados	2
2 Carga dos Dados	2
3 Modelagem e Catálogo de Dados	4
Catálogo dos campos de origem e da tabela Silver	4
Campos adicionais da Bronze e da Silver	5
Catálogo das três tabelas Gold	5
4 Pipeline de Dados	6
5 Qualidade de Dados	7
6 Análise de Dados	10
Cumprimento das metas por setor	10
Variação ao longo do período e entre equipes	11
Indicadores operacionais segundo o cumprimento da meta	13
Síntese das perguntas e respostas	14
Considerações finais	14
Pontos de melhoria	15
7 Autoavaliação	15
Referências	15

1 Contexto de Negócios e Perguntas

Em uma indústria de confecção, diferentes equipes recebem metas de produtividade e registram o resultado de seu trabalho. Para acompanhar essas operações, é útil identificar onde a meta é cumprida e como variam os resultados por setor, equipe e data. O objetivo deste MVP é transformar um arquivo público com registros de produtividade em tabelas consultáveis no Databricks e utilizá-las para examinar o cumprimento das metas.

As perguntas que orientaram a modelagem e as consultas são:

1. Qual proporção de registros atinge ou supera a meta de produtividade em cada setor?
2. Como a produtividade realizada e o cumprimento da meta variam entre equipes e ao longo das datas disponíveis?
3. Como variam as médias de tempo extra, tempo de inatividade e trabalho em andamento entre os registros que atingem e os que não atingem a meta?

Fonte dos dados

Foi utilizado o arquivo `garments_worker_productivity.csv` do conjunto Productivity Prediction of Garment Employees, disponibilizado pela UCI Machine Learning Repository (DOI 10.24432/C51S6D). A página da UCI informa licença Creative Commons Attribution 4.0 International (CC BY 4.0). Os registros se referem à indústria de confecção.

The screenshot shows the UCI Machine Learning Repository page for the 'Productivity Prediction of Garment Employees' dataset. The page includes a header with the UCI logo and navigation links. The main content area features a blue header with the dataset name and a 'Donated on 8/2/2020' note. Below this, there is a description of the dataset and a table with three columns: 'Dataset Characteristics', 'Subject Area', and 'Associated Tasks'. The 'Dataset Characteristics' column lists 'Multivariate, Time-Series' and 'Feature Type' as 'Integer, Real'. The 'Subject Area' column lists 'Business' and '# Instances' as '1197'. The 'Associated Tasks' column lists 'Classification, Regression' and '# Features' as '14'. To the right of the table, there are buttons for 'DOWNLOAD (92.9 KB)', 'IMPORT IN PYTHON', and 'CITE'. Below these buttons, there are statistics: '1 citations' and '65430 views'. The 'DOI' is listed as '10.24432/C51S6D'. The 'License' section states that the dataset is licensed under a 'Creative Commons Attribution 4.0 International (CC BY 4.0)' license.

Dataset Characteristics	Subject Area	Associated Tasks
Multivariate, Time-Series	Business	Classification, Regression
Feature Type Integer, Real	# Instances 1197	# Features 14

Figura 1 — Página do conjunto Productivity Prediction of Garment Employees na UCI Machine Learning Repository. Fonte: UCI (2020).

O CSV contém 1.197 linhas e 15 colunas: `date`, `quarter`, `department`, `day`, `team`, `targeted_productivity`, `smv`, `wip`, `over_time`, `incentive`, `idle_time`, `idle_men`, `no_of_style_change`, `no_of_workers` e `actual_productivity`. Há 59 datas de 1º de janeiro a 11 de março de 2015. Cada linha descreve o registro de uma equipe em um setor e uma data. A chave composta por data, setor padronizado e equipe não apresenta repetições no arquivo analisado.

Fonte e licença: <https://archive.ics.uci.edu/dataset/597/productivity+prediction+of+garment+employees>

2 Carga dos Dados

O CSV foi obtido na página da UCI e enviado manualmente ao volume `entrada_uci` do esquema `workspace.mvp_produtividade`, no Databricks Free Edition. O caminho utilizado pelo notebook é

/Volumes/workspace/mvp_produtividade/entrada_uci/garments_worker_productivity.csv. O arquivo permanece nesse volume como origem para eventuais reexecuções.




Figura 2 — Arquivo garments_worker_productivity.csv armazenado no volume entrada_uci do Databricks.

Fonte: elaboração própria.

```
CATALOG = "workspace"
SCHEMA = "mvp_produtividade"
VOLUME = "entrada_uci"
CSV_NAME = "garments_worker_productivity.csv"

spark.sql(f"CREATE SCHEMA IF NOT EXISTS `{CATALOG}`.`{SCHEMA}`")
spark.sql(f"CREATE VOLUME IF NOT EXISTS `{CATALOG}`.`{SCHEMA}`.`{VOLUME}`")
CSV_PATH = f"/Volumes/{CATALOG}/{SCHEMA}/{VOLUME}/{CSV_NAME}"
TABLE_PREFIX = f"{CATALOG}.{SCHEMA}"
```

Figura 3 — Configuração do esquema, do volume e do caminho do CSV no Databricks.

Fonte: elaboração própria.

No notebook 01_pipeline_produtividade.py, o Spark lê o cabeçalho sem inferir tipos e confere os 15 nomes de coluna esperados. Os campos são preservados como texto na tabela Delta bronze_produtividade; apenas source_file, que identifica o CSV, e ingested_at, que registra a ingestão, são acrescentados. A execução registrou 1.197 linhas nessa tabela. O modo FAILFAST interrompe a leitura de registros CSV malformados; uma validação separada confere os nomes e a ordem das 15 colunas.




Figura 4 — Leitura do CSV, gravação da tabela Bronze e conferência dos 1.197 registros. Fonte: elaboração própria.

Código do pipeline: https://github.com/izisdornelas/mvp-engenharia-dados-produtividade/blob/main/01_pipeline_produtividade.py

3 Modelagem e Catálogo de Dados

O modelo organiza os dados em uma tabela de entrada, uma tabela detalhada tratada e três tabelas de agregação. Cada agregação responde a uma necessidade de consulta; não há tabelas de dimensões nem junções, pois o arquivo de origem contém uma única relação de registros de produtividade.

Tabela no esquema workspace.mvp_produtividade	Grão e conteúdo	Linhas
bronze_produtividade	Uma linha do CSV; valores originais e metadados de ingestão.	1.197
silver_produtividade	Data, setor e equipe; tipos corrigidos e indicadores de validação.	1.197
gold_produtividade_setor	Um setor; síntese das metas e indicadores operacionais.	2
gold_produtividade_dia_setor	Uma data e um setor; evolução dos indicadores.	118
gold_produtividade_equipe	Um setor e uma equipe; comparação entre equipes.	24




Figura 5 — Cinco tabelas persistidas no esquema workspace.mvp_produtividade do Databricks. Fonte: elaboração própria.

Catálogo dos campos de origem e da tabela Silver

Na Bronze, os 15 campos originais abaixo têm tipo STRING. Na Silver, os nomes e tipos resultam das conversões indicadas. Os intervalos são os valores observados neste arquivo e não regras universais para futuros dados.

Origem e nome na Silver	Tipo Silver	Definição e domínio observado
date → data_registro	DATE	Data da produção; de 01/01 a 11/03/2015.
quarter → quarter	STRING	Parte do mês. Quarter1, Quarter2, Quarter3, Quarter4 e Quarter5 no arquivo.

Origem e nome na Silver	Tipo Silver	Definição e domínio observado
department → setor_original, setor	STRING	Texto recebido e setor padronizado: sewing ou finishing.
day → day	STRING	Dia da semana, de Monday a Sunday, exceto Friday no período observado.
team → equipe	INT	Identificação numérica da equipe, de 1 a 12.
targeted_productivity	DOUBLE	Produtividade prevista como meta, de 0,07 a 0,8.
smv	DOUBLE	Standard Minute Value, de 2,9 a 54,56.
wip	DOUBLE	Trabalho em andamento; 7 a 23.122 quando informado.
over_time	DOUBLE	Tempo extra da equipe em minutos, de 0 a 25.920.
incentive	DOUBLE	Incentivo em BDT, de 0 a 3.600.
idle_time	DOUBLE	Tempo de interrupção, de 0 a 300; unidade não especificada pela UCI.
idle_men	DOUBLE	Número de pessoas ociosas, de 0 a 45.
no_of_style_change	DOUBLE	Mudanças de estilo do produto, de 0 a 2.
no_of_workers	DOUBLE	Número de trabalhadores, de 2 a 89; há valores fracionários na fonte.
actual_productivity	DOUBLE	Produtividade realizada, de 0,233705476 a 1,1204375.

A Bronze ainda contém source_file (STRING) e ingested_at (TIMESTAMP). A Silver preserva source_file, quarter, day e as medidas, além de conter atingiu_meta, produtividade_acima_de_um e dia_confere (BOOLEAN). O primeiro indicador compara produtividade realizada com a meta; o segundo sinaliza valores acima de 1; o terceiro confere o dia da semana com a data convertida.

Campos adicionais da Bronze e da Silver

Campo	Tabela e tipo	Origem, significado e domínio
source_file	Bronze e Silver · STRING	Nome do CSV carregado; nesta carga, garments_worker_productivity.csv.
ingested_at	Bronze · TIMESTAMP	Data e hora atribuídas pelo pipeline à gravação da Bronze.
setor_original	Silver · STRING	Cópia de department, preservando a grafia recebida.
setor	Silver · STRING	department sem espaços nas extremidades, em minúsculas, com sweing corrigido para sewing; valores finais: sewing e finishing.
atingiu_meta	Silver · BOOLEAN	Verdadeiro quando actual_productivity >= targeted_productivity.
produtividade_acima_de_um	Silver · BOOLEAN	Verdadeiro quando actual_productivity > 1; sinaliza o valor sem alterá-lo.
dia_confere	Silver · BOOLEAN	Confere se o dia da semana calculado de data_registro corresponde a day.

Catálogo das três tabelas Gold

As tabelas Gold são calculadas exclusivamente a partir da Silver, sem junções. A linhagem dos dados começa no CSV armazenado no volume entrada_uci, passa pela Bronze, que preserva os dados recebidos, e pela Silver, que converte tipos, padroniza o setor e cria os indicadores. A gold_produtividade_setor agrupa por setor (STRING); a gold_produtividade_dia_setor, por data_registro (DATE) e setor (STRING); e a gold_produtividade_equipe, por setor (STRING) e equipe (INT). Os nove campos restantes são calculados para cada grupo e estão descritos na tabela a seguir:

Campo	Tipo	Definição
registros	BIGINT	Quantidade de registros do grupo.
metas_atingidas	BIGINT	Quantidade de registros com atingiu_meta verdadeiro.

Campo	Tipo	Definição
percentual_metas_atingidas	DOUBLE	100 vezes a proporção de metas atingidas no grupo.
meta_media	DOUBLE	Média de targeted_productivity.
produtividade_media	DOUBLE	Média de actual_productivity.
minutos_extras_medios	DOUBLE	Média de over_time, em minutos.
inatividade_media	DOUBLE	Média de idle_time, cuja unidade não consta na fonte.
registros_wip_informado	BIGINT	Quantidade de registros não nulos de wip.
wip_medio_informado	DOUBLE	Média de wip somente nos registros informados; nula sem observações.

Nas tabelas Gold, registros, metas_atingidas e registros_wip_informado são contagens inteiras não negativas. As duas últimas não excedem registros. percentual_metas_atingidas varia de 0 a 100. As médias mantêm as unidades das medidas de origem; wip_medio_informado permanece nulo quando não há registros com wip informado.

Considerando os grupos das três tabelas Gold, os intervalos observados foram: registros, de 4 a 691; metas_atingidas, de 1 a 573; percentual_metas_atingidas, de 12,50% a 100%; meta_media, de 0,6600 a 0,7889; produtividade_media, de 0,5807 a 0,9719; minutos_extras_medios, de 0 a 12.377,50; inatividade_media, de 0 a 47,50; e registros_wip_informado, de 0 a 691. Entre os grupos com wip informado, wip_medio_informado variou de 773,74 a 11.933,00. Esses intervalos descrevem os dados analisados; não são limites obrigatórios para futuras cargas.

4 Pipeline de Dados

O notebook executa a sequência CSV → Bronze → análise inicial de qualidade → Silver → Gold → consultas. A Bronze conserva os dados de entrada. Na Silver, date passa a DATE, team a INT e as medidas numéricas a DOUBLE. O texto do setor é aparado; a grafia sweing é registrada em setor_original e corrigida para sewing em setor. O cálculo atingiu_meta compara a produtividade realizada à meta linha a linha.

Antes de gravar a Silver, o código interrompe a execução se houver nulos nos campos obrigatórios, divergências entre data e dia da semana ou repetição da chave data, setor e equipe. Os 506 wip ausentes continuam nulos; tratá-los como zero alteraria o significado da medida. Os 37 valores de actual_productivity acima de 1 são conservados e sinalizados para exame. A verificação dos dez campos numéricos confirmou que nenhum valor preenchido no CSV se tornou nulo durante a conversão de tipos.

```
numeric_columns = ["targeted_productivity", "smv", "wip", "over_time", "incentive", "idle_time", "idle_men", "no_of_style_change", "no_of_workers",
"actual_productivity"]
typed = br.select(*[F.col(c) for c in source_columns], "source_file")
typed = typed.withColumn("data_registro", F.to_date("date", "M/d/yyyy"))
typed = typed.withColumn("equipe", F.expr("try_cast(team as int)"))
typed = typed.withColumn("setor_original", F.col("department"))
typed = typed.withColumn("setor", F.when(F.lower(F.trim("department")) == "sweing", F.lit("sewing")).otherwise(F.lower(F.trim("department"))))
for field in numeric_columns:
    typed = typed.withColumn(field, F.expr(f"try_cast(trim(`{field}`) as double)"))
typed = typed.withColumn("atingiu_meta", F.col("actual_productivity") >= F.col("targeted_productivity"))
typed = typed.withColumn("produtividade_acima_de_um", F.col("actual_productivity") > 1)
typed = typed.withColumn("dia_confere", F.date_format("data_registro", "EEEE") == F.col("day"))

# Falhas de conversão dos campos obrigatórios interrompem o pipeline, sem perda silenciosa.
required = ["data_registro", "equipe", "targeted_productivity", "actual_productivity"]
bad_required = typed.filter(F.expr(" OR ".join(f"`{x}` IS NULL" for x in required))).count()
assert bad_required == 0, f"Campos obrigatórios inválidos em {bad_required} linhas"
bad_day = typed.filter(~F.col("dia_confere") | F.col("dia_confere").isNull()).count()
assert bad_day == 0, f"Dia da semana inconsistente em {bad_day} linhas"
duplicate_keys = typed.groupBy("data_registro", "setor", "equipe").count().filter("count > 1").count()
assert duplicate_keys == 0, f"Chaves repetidas após padronização: {duplicate_keys}"

silver = typed.drop("date", "department", "team")
silver.write.format("delta").mode("overwrite").option("overwriteSchema", "true").saveAsTable(f"{TABLE_PREFIX}.silver_produtividade")
print("Linhas Silver:", spark.table(f"{TABLE_PREFIX}.silver_produtividade").count())
```

See performance (5) ✓ Checked for improvements

2 dataframes: silver, typed

Linhas Silver: 1197

Figura 6 — Conversão, padronização e verificações da camada Silver, com 1.197 registros. Fonte: elaboração própria.

As três tabelas Gold calculam contagens, percentuais e médias por setor, por data e setor e por setor e equipe. A gravação em Delta com modo overwrite substitui as tabelas em cada execução e evita o acúmulo de linhas ao processar novamente o mesmo CSV. A tabela por setor soma 1.197 registros, quantidade igual à da Silver; as três Gold possuem, respectivamente, 2, 118 e 24 linhas.

```
def measures(grouped):
    return grouped.agg(
        F.count("*").alias("registros"),
        F.sum(F.col("atingiu_meta").cast("long")).alias("metas_atingidas"),
        F.round(100 * F.avg(F.col("atingiu_meta").cast("double")), 2).alias("percentual_metas_atingidas"),
        F.round(F.avg("targeted_productivity"), 4).alias("meta_media"),
        F.round(F.avg("actual_productivity"), 4).alias("produtividade_media"),
        F.round(F.avg("over_time"), 2).alias("minutos_extras_medios"),
        F.round(F.avg("idle_time"), 2).alias("inatividade_media"),
        F.count("wip").alias("registros_wip_informado"),
        F.round(F.avg("wip"), 2).alias("wip_medio_informado"),
    )

gold = {
    "gold_produtividade_setor": measures(s.groupBy("setor")),
    "gold_produtividade_dia_setor": measures(s.groupBy("data_registro", "setor")),
    "gold_produtividade_equipe": measures(s.groupBy("setor", "equipe")),
}
for name, frame in gold.items():
    frame.write.format("delta").mode("overwrite").option("overwriteSchema", "true").saveAsTable(f"{TABLE_PREFIX}.{name}")
    print(name, spark.table(f"{TABLE_PREFIX}.{name}").count(), "linhas")
assert spark.table(f"{TABLE_PREFIX}.gold_produtividade_setor").agg(F.sum("registros")).first()[0] == s.count()
```

> [See performance \(8\)](#)

```
gold_produtividade_setor 2 linhas
gold_produtividade_dia_setor 118 linhas
gold_produtividade_equipe 24 linhas
```

Figura 7 — Criação das tabelas Gold por setor, por dia e setor, e por equipe. Fonte: elaboração própria.

5 Qualidade de Dados

A conferência inicial examinou a completude de cada coluna, a consistência de categorias e datas, a duplicação de linhas e chaves e os limites observados nas medidas numéricas. Na execução em nuvem, a Bronze apresentou 1.197 linhas e nenhuma linha inteiramente duplicada. A Silver manteve as 1.197 linhas após conversão, com validações de campos obrigatórios, dia da semana e chave composta concluídas sem falhas.

```
br = spark.table(f"{TABLE_PREFIX}.bronze_produtividade")
for field in source_columns:
    missing = br.filter(F.col(field).isNull() | (F.trim(F.col(field)) == "")).count()
    distinct = br.select(field).distinct().count()
    print(f"{field}: ausentes={missing}, distintos={distinct}")
print("Linhas completamente duplicadas:", br.groupBy(*source_columns).count().filter("count > 1").agg(F.sum(F.col("count") - 1)).first()[0] or 0)
display(br.groupBy("department").agg(F.count("*").alias("linhas"), F.sum(F.when(F.col("wip").isNull() | (F.trim("wip") == ""), 1).otherwise(0)).alias("wip_ausente")))
```

> [See performance \(32\)](#) ✓ Checked for improvements

```
br: pyspark.sql.connect.dataframe.DataFrame
  date: string
  quarter: string
  department: string
  day: string
  team: string
  targeted_productivity: string
  smv: string
  wip: string
  over_time: string
  incentive: string
  idle_time: string
  idle_men: string
  no_of_style_change: string
  no_of_workers: string
  actual_productivity: string
  source_file: string
  ingested_at: timestamp
```

Figura 8 — Código do perfil inicial da Bronze. Fonte: elaboração própria.

```

date: ausentes=0, distintos=59
quarter: ausentes=0, distintos=5
department: ausentes=0, distintos=3
day: ausentes=0, distintos=6
team: ausentes=0, distintos=12
targeted_productivity: ausentes=0, distintos=9
smv: ausentes=0, distintos=70
wip: ausentes=506, distintos=549
over_time: ausentes=0, distintos=143
incentive: ausentes=0, distintos=48
idle_time: ausentes=0, distintos=12
idle_men: ausentes=0, distintos=10
no_of_style_change: ausentes=0, distintos=3
no_of_workers: ausentes=0, distintos=61
actual_productivity: ausentes=0, distintos=879
Linhas completamente duplicadas: 0

```

Table  

	A ^B C department	1 ² ₃ linhas	1 ² ₃ wip_ausente
1	sweing	691	0
2	finishing	257	257
3	finishing	249	249

Figura 9 — Resultado do perfil inicial da Bronze. Fonte: elaboração própria.

A única coluna original com ausências é wip: 506 registros, equivalentes a 42,27% do total. Todas as ausências pertencem a finishing; os 691 registros de sewing possuem wip informado. Isso restringe a comparação dessa medida: não há média observada de wip para finishing. Por essa razão, as tabelas Gold apresentam tanto a média quanto a contagem que a sustenta.

A fonte possui três grafias do departamento: sweing (691 linhas), finishing (249) e finishing com espaço final (257). Após retirar espaços e corrigir sweing, há dois setores. O arquivo também contém Quarter5, embora a descrição resumida da UCI diga que o mês se divide em quatro partes; a categoria original foi mantida, sem tratá-la como trimestre do ano.

A produtividade realizada vai de 0,233705476 a 1,1204375. Como a descrição da UCI menciona intervalo de 0 a 1, os 37 valores acima de 1 foram sinalizados, sem truncamento. O maior wip informado é 23.122 e o maior over_time é 25.920 minutos. São valores que merecem investigação com informações adicionais do processo; os dados disponíveis não permitem classificá-los como erros de medição.


Para examinar valores extremos nos dez atributos numéricos, foi aplicado o critério do intervalo interquartil (IQR): valores abaixo de $Q1 - 1,5 \times IQR$ ou acima de $Q3 + 1,5 \times IQR$ foram sinalizados para investigação. Quando Q1 e Q3 coincidiram, o IQR foi zero e o critério não foi aplicado, pois qualquer valor diferente de Q1 seria sinalizado. Os registros sinalizados foram preservados; a identificação estatística de um extremo não comprova erro de medição.

Atributo	Limites IQR aproximados	Registros sinalizados
targeted_productivity	0,55 a 0,95	79
smv	-26,54 a 54,74	0
wip	51,50 a 1.975,50	21
over_time	-6.840,00 a 15.240,00	1
incentive	-75,00 a 125,00	11
idle_time	IQR = 0; critério não aplicado	—

Atributo	Limites IQR aproximados	Registros sinalizados
idle_men	IQR = 0; critério não aplicado	—
no_of_style_change	IQR = 0; critério não aplicado	—
no_of_workers	−63,00 a 129,00	0
actual_productivity	0,35 a 1,15	54

```
s = spark.table(f"{TABLE_PREFIX}.silver_produtividade")
assert s.count() == br.count(), "A transformação alterou o número de linhas"
print("WIP nulo:", s.filter(F.col("wip").isNull()).count())
print("Produtividade > 1:", s.filter("produtividade_acima_de_um").count())
for field in numeric_columns:
    values = s.agg(F.count(F.col(field)).alias("informados"), F.min(field).alias("minimo"), F.max(field).alias("maximo")).first()
    print(field, values.asDict())
print("Categorias de subdivisão do mês e de setor:")
display(s.groupBy("quarter", "setor").count().orderBy("quarter", "setor"))
```

> [See performance \(15\)](#)

>  pyspark.sql.connect.dataframe.DataFrame = [quarter: string, day: string ... 18 more fields]

WIP nulo: 506

Produtividade > 1: 37

targeted_productivity {'informados': 1197, 'minimo': 0.07, 'maximo': 0.8}

smv {'informados': 1197, 'minimo': 2.9, 'maximo': 54.56}

wip {'informados': 691, 'minimo': 7.0, 'maximo': 23122.0}

over_time {'informados': 1197, 'minimo': 0.0, 'maximo': 25920.0}

incentive {'informados': 1197, 'minimo': 0.0, 'maximo': 3600.0}

idle_time {'informados': 1197, 'minimo': 0.0, 'maximo': 300.0}

idle_men {'informados': 1197, 'minimo': 0.0, 'maximo': 45.0}

no_of_style_change {'informados': 1197, 'minimo': 0.0, 'maximo': 2.0}

no_of_workers {'informados': 1197, 'minimo': 2.0, 'maximo': 89.0}

actual_productivity {'informados': 1197, 'minimo': 0.233705476, 'maximo': 1.1204375}

Categorias de subdivisão do mês e de setor:

Table  

	A ^B quarter	A ^B setor	1 ² 3 count
1	Quarter1	finishing	149
2	Quarter1	sewing	211
3	Quarter2	finishing	147
4	Quarter2	sewing	188
5	Quarter3	finishing	81
6	Quarter3	sewing	129
7	Quarter4	finishing	108
8	Quarter4	sewing	140
9	Quarter5	finishing	21
10	Quarter5	sewing	23

Figura 10 — Verificações da Silver: valores ausentes, produtividade acima de 1 e limites das medidas. Fonte: elaboração própria.

```

# Triagem de valores extremos pelo intervalo interquartil (IQR).
# Registros sinalizados são candidatos à investigação, não erros confirmados.
from pyspark.sql import functions as F

s = spark.table("workspace.mvp_produtividade.silver_produtividade")

numeric_columns = [
    "targeted_productivity", "smv", "wip", "over_time",
    "incentive", "idle_time", "idle_men", "no_of_style_change",
    "no_of_workers", "actual_productivity"
]

for campo in numeric_columns:
    valores = s.where(F.col(campo).isNotNull())
    q1, q3 = valores.approxQuantile(campo, [0.25, 0.75], 0)
    iqr = q3 - q1
    if iqr == 0:
        print(f"{campo}: Q1={q1:.2f}; Q3={q3:.2f}; IQR=0; "
              "critério de extremos não aplicado")
        continue
    inferior = q1 - 1.5 * iqr
    superior = q3 + 1.5 * iqr
    extremos = valores.where(
        (F.col(campo) < inferior) | (F.col(campo) > superior)
    ).count()
    print(
        f"{campo}: Q1={q1:.2f}; Q3={q3:.2f}; "
        f"limites=[{inferior:.2f}, {superior:.2f}]; "
        f"candidatos={extremos}"
    )

```

> [See performance \(17\)](#)

> `s: pyspark.sql.connect.dataframe.DataFrame = [quarter: string, day: string ... 18 more fields]`

```

targeted_productivity: Q1=0.70; Q3=0.80; limites=[0.55, 0.95]; candidatos=79
smv: Q1=3.94; Q3=24.26; limites=[-26.54, 54.74]; candidatos=0
wip: Q1=773.00; Q3=1254.00; limites=[51.50, 1975.50]; candidatos=21
over_time: Q1=1440.00; Q3=6960.00; limites=[-6840.00, 15240.00]; candidatos=1
incentive: Q1=0.00; Q3=50.00; limites=[-75.00, 125.00]; candidatos=11
idle_time: Q1=0.00; Q3=0.00; IQR=0; critério de extremos não aplicado
idle_men: Q1=0.00; Q3=0.00; IQR=0; critério de extremos não aplicado
no_of_style_change: Q1=0.00; Q3=0.00; IQR=0; critério de extremos não aplicado
no_of_workers: Q1=9.00; Q3=57.00; limites=[-63.00, 129.00]; candidatos=0
actual_productivity: Q1=0.65; Q3=0.85; limites=[0.35, 1.15]; candidatos=54

```

Figura 11 — Triagem de valores extremos pelo método IQR: código e resultados para os atributos numéricos da Silver.
Fonte: elaboração própria.

6 Análise de Dados

Cumprimento das metas por setor

A meta foi atingida ou superada em 302 dos 506 registros de finishing, ou 59,68%, e em 573 dos 691 registros de sewing, ou 82,92%. A diferença é de 23,24 pontos percentuais. Embora a produtividade média realizada seja 0,753 em finishing e 0,722 em sewing, esse valor isolado não mede a frequência de cumprimento da meta, porque as metas variam entre os registros.

```
print("Pergunta 1: cumprimento das metas por setor")
display(spark.sql(f"SELECT * FROM {TABLE_PREFIX}.gold_produtividade_setor ORDER BY setor"))
```

Figura 12 — Consulta do cumprimento das metas por setor. Fonte: elaboração própria.

	setor	registros	metas atingidas	percentual metas atingidas	meta média	produtividade média
1	finishing	506	302	59,68	0,7374	0,753
2	sewing	691	573	82,92	0,724	0,722

Figura 13 — Registros, metas atingidas e produtividade por setor. Fonte: elaboração própria.

Variação ao longo do período e entre equipes

A Gold diária contém 118 grupos, correspondentes a 59 datas em cada setor. Para resumir a evolução sem calcular uma média simples de percentuais diários, a tabela abaixo divide o número de metas atingidas pelo total de registros de cada mês e setor. Os valores foram calculados a partir da tabela Gold diária, somando os registros e as metas atingidas de cada mês e setor.

Mês de 2015	finishing	sewing
Janeiro	154/235 = 65,53%	269/307 = 87,62%
Fevereiro	92/174 = 52,87%	201/269 = 74,72%
Março, até o dia 11	56/97 = 57,73%	103/115 = 89,57%

```

print("Pergunta 2: resumo mensal por setor")
mensal = (
    spark.table(f"{TABLE_PREFIX}.gold_produtividade_dia_setor")
    .groupBy(
        F.date_format("data_registro", "yyyy-MM").alias("mes"),
        "setor"
    )
    .agg(
        F.sum("registros").alias("registros"),
        F.sum("metas_atingidas").alias("metas_atingidas")
    )
    .withColumn(
        "percentual_metas_atingidas",
        F.round(100 * F.col("metas_atingidas") / F.col("registros"), 2)
    )
    .orderBy("mes", "setor")
)
display(mensal)

```

Pergunta 2: resumo mensal por setor

Table +

	^A _C mes	^A _C setor	¹ ₃ registros	¹ ₃ metas_atingidas	^{1.2} percentual_metas_atingidas
1	2015-01	finishing	235	154	65.53
2	2015-01	sewing	307	269	87.62
3	2015-02	finishing	174	92	52.87
4	2015-02	sewing	269	201	74.72
5	2015-03	finishing	97	56	57.73
6	2015-03	sewing	115	103	89.57

↓ ▼ 6 rows | 5.686s runtime

Figura 14 — Consulta mensal por setor a partir da Gold diária: código e resultados. Fonte: elaboração própria.

```

print("Pergunta 2: evolução diária por setor e resultados por equipe")
display(spark.sql(f"SELECT * FROM {TABLE_PREFIX}.gold_produtividade_dia_setor ORDER BY data_registro, setor"))
display(spark.sql(f"SELECT * FROM {TABLE_PREFIX}.gold_produtividade_equipe ORDER BY setor, equipe"))

```

Figura 15 — Consultas dos resultados por dia e setor e por equipe. Fonte: elaboração própria.

Pergunta 2: evolução diária por setor e resultados por equipe

	data_registro	setor	registros	metas_atingidas	percentual_metas_atingidas	meta_media	produtividade_media	minutos_ext
1	2015-01-01	finishing	7	3	42.86	0.7357	0.6563	
2	2015-01-01	sewing	12	9	75	0.7625	0.7551	
3	2015-01-03	finishing	9	6	66.67	0.7778	0.8354	
4	2015-01-03	sewing	12	11	91.67	0.775	0.7783	
5	2015-01-04	finishing	9	5	55.56	0.7778	0.7719	
6	2015-01-04	sewing	12	10	83.33	0.775	0.7864	
7	2015-01-05	finishing	10	8	80	0.77	0.8159	
8	2015-01-05	sewing	12	12	100	0.775	0.7795	
9	2015-01-06	finishing	9	7	77.78	0.7889	0.8291	
10	2015-01-06	sewing	12	11	91.67	0.7792	0.7878	
11	2015-01-07	finishing	10	7	70	0.78	0.7591	
12	2015-01-07	sewing	12	11	91.67	0.7875	0.7722	
13	2015-01-08	finishing	10	6	60	0.78	0.7841	
14	2015-01-08	sewing	12	10	83.33	0.75	0.7405	

Figura 16 — Exemplo dos resultados diários por setor. Fonte: elaboração própria.

	setor	equipe	registros	metas_atin...	percentual_metas_atingidas	meta_media	produtividade_media	minutos_ext
1	finishing	1	49	37	75.51	0.75	0.8278	
2	finishing	2	52	35	67.31	0.7529	0.7801	
3	finishing	3	37	31	83.78	0.7405	0.8473	
4	finishing	4	46	33	71.74	0.7185	0.8206	
5	finishing	5	35	28	80	0.66	0.7916	
6	finishing	6	35	11	31.43	0.7229	0.6279	
7	finishing	7	41	17	41.46	0.7305	0.6858	
8	finishing	8	53	19	35.85	0.7132	0.6927	
9	finishing	9	46	26	56.52	0.7761	0.7245	
10	finishing	10	43	26	60.47	0.7535	0.7234	
11	finishing	11	29	14	48.28	0.7362	0.6938	
12	finishing	12	40	25	62.5	0.7788	0.7923	
13	sewing	1	56	53	94.64	0.7438	0.8151	
14	sewing	2	57	47	82.46	0.7281	0.7624	

Figura 17 — Exemplo dos resultados por equipe. Fonte: elaboração própria.

Nos dois setores, a proporção de metas atingidas foi menor em fevereiro que em janeiro. Março inclui somente parte do mês e deve ser interpretado nessa condição. Nas agregações por equipe também há diferenças: a equipe 6 de finishing cumpriu 11 metas em 35 registros (31,43%), enquanto a equipe 1 de sewing cumpriu 53 em 56 (94,64%). Essas diferenças descrevem os grupos observados; não isolam tipo de tarefa, composição das equipes ou dificuldade das metas.

Indicadores operacionais segundo o cumprimento da meta

Em sewing, os 118 registros que não atingiram a meta tiveram média de idle_time de 5,31, ante 0,43 nos 573 registros que a atingiram. As médias de over_time foram, respectivamente, 6.394,58 e 6.531,61 minutos. Entre os registros com wip informado, as médias foram 845,58 e 1.261,49 itens, respectivamente.

Em finishing, 204 registros não atingiram a meta e 302 atingiram. O over_time médio foi, respectivamente, 1.849,41 e 1.962,91 minutos; o idle_time médio foi zero em ambos os grupos. Nenhum registro desse setor informa wip. Essas comparações mostram associações descritivas dentro do período analisado; não estabelecem que o tempo extra, a inatividade ou o trabalho em andamento tenham causado o resultado de produtividade.

```
print("Pergunta 3: indicadores operacionais por setor e cumprimento de meta")
display(s.groupby("setor", "atingiu_meta").agg(
    F.count("*").alias("registros"), F.round(F.avg("over_time"), 2).alias("minutos_extras_medios"),
    F.round(F.avg("idle_time"), 2).alias("inatividade_mediana"),
    F.count("wip").alias("registros_wip_informado"), F.round(F.avg("wip"), 2).alias("wip_medio_informado")
).orderBy("setor", "atingiu_meta"))
```

Figura 18 — Código da consulta dos indicadores operacionais por setor e cumprimento da meta. Fonte: elaboração própria.

Pergunta 3: indicadores operacionais por setor e cumprimento de meta

	setor	atingiu_meta	registros	1.2 minutos_extras_medios	1.2 inatividade_mediana	registros_wip_informado	1.2 wip_medio_informado
1	finishing	false	204	1849.41	0	0	null
2	finishing	true	302	1962.91	0	0	null
3	sewing	false	118	6394.58	5.31	118	845.58
4	sewing	true	573	6531.61	0.43	573	1261.49

Figura 19 — Indicadores operacionais por setor e cumprimento da meta. Fonte: elaboração própria.

Síntese das perguntas e respostas

1. Qual proporção de registros atinge ou supera a meta de produtividade em cada setor?

Em finishing, a meta foi atingida em 302 de 506 registros (59,68%). Em sewing, foram 573 de 691 (82,92%). A diferença é de 23,24 pontos percentuais. Trata-se da frequência de cumprimento da meta em cada setor, não de uma comparação direta das médias de produtividade, pois as metas variam entre os registros.

2. Como a produtividade realizada e o cumprimento da meta variam entre equipes e ao longo das datas disponíveis?

As tabelas Gold permitem examinar a produtividade média e o cumprimento da meta por data e setor e por setor e equipe. Nos dois setores, a proporção de metas atingidas foi menor em fevereiro do que em janeiro: passou de 65,53% para 52,87% em finishing e de 87,62% para 74,72% em sewing. Entre as equipes mostradas nos resultados, a equipe 6 de finishing atingiu 11 metas em 35 registros (31,43%), enquanto a equipe 1 de sewing atingiu 53 em 56 (94,64%). Nesse recorte, as produtividades médias realizadas dessas equipes foram 0,6279 e 0,8151, respectivamente; em 1º de janeiro, as médias diárias foram 0,6563 em finishing e 0,7551 em sewing. Março contém somente parte do mês, e esses resultados não isolam diferenças nas tarefas ou nas metas atribuídas.

3. Como variam as médias de tempo extra, tempo de inatividade e trabalho em andamento entre os registros que atingem e os que não atingem a meta?

Em sewing, o idle_time médio foi 5,31 nos registros que não atingiram a meta e 0,43 nos que a atingiram. O over_time médio foi, respectivamente, 6.394,58 e 6.531,61 minutos; o wip médio entre registros informados foi 845,58 e 1.261,49 itens. Em finishing, o idle_time médio foi zero nos dois grupos e nenhum registro informou wip. São comparações descritivas: elas não demonstram que esses indicadores causaram o resultado da meta.

Considerações finais

As consultas mostram como o pipeline permite passar de registros individuais para diferentes perspectivas de análise: setor, período, equipe e indicadores operacionais. Os resultados ajudam a identificar grupos que merecem exame mais detalhado, mas precisam ser interpretados à luz das limitações da base. Sem informações adicionais sobre tarefas, condições de operação e definição das metas, as diferenças observadas não permitem atribuir causas nem avaliar isoladamente o desempenho das equipes.

A preservação dos valores de origem foi importante para essa interpretação. As ausências de wip permaneceram nulas, e as produtividades acima de 1 e os valores extremos foram sinalizados sem descarte automático. Assim, as decisões de tratamento ficam explícitas e podem ser revistas caso novas informações sobre a coleta se tornem disponíveis.

Pontos de melhoria

Uma próxima etapa seria reunir informações sobre os processos de trabalho e os critérios das metas para investigar os grupos destacados nas consultas. Também seria útil esclarecer a ausência de wip em finishing e verificar os valores extremos com quem conhece a operação que gerou os registros. Na parte técnica, a carga manual e estática do CSV poderia evoluir para atualizações periódicas acompanhadas de verificações de qualidade.

7 Autoavaliação

O objetivo definido para este MVP foi atingido: os dados públicos foram carregados no Databricks, preservados na Bronze, tratados na Silver e organizados em tabelas Gold que sustentam as consultas apresentadas. A execução e as evidências documentadas permitem acompanhar o caminho dos dados desde o arquivo recebido até os resultados analisados.

As principais dificuldades estiveram na carga do arquivo para a plataforma, na conferência das tabelas persistidas e nas decisões de tratamento dos dados. Foi necessário distinguir ausência de valor de valor zero, padronizar a identificação do setor sem perder a informação original e registrar ocorrências que exigem investigação sem classificá-las automaticamente como erros. Essas escolhas tornaram a análise mais verificável.

O trabalho entrega uma solução funcional para as perguntas propostas, dentro do alcance do conjunto de dados utilizado. Seu limite principal é a falta de contexto operacional para explicar as diferenças encontradas. As melhorias indicadas nas considerações finais oferecem um caminho para ampliar o projeto sem apresentar as conclusões descritivas atuais como relações de causa e efeito.

Referências

UCI Machine Learning Repository. Productivity Prediction of Garment Employees. DOI: 10.24432/C51S6D. <https://archive.ics.uci.edu/dataset/597/productivity+prediction+of+garment+employees>

Dornelas, Izis. MVP de Engenharia de Dados: produtividade no chão de fábrica. Código e notebook exportado. <https://github.com/izisdornelas/mvp-engenharia-dados-produtividade>